

2023 台北市捷運 / 公車轉乘 YOUBIKE 每日租借量分析報告

組別： 第22組

組員： 蔡明賢 7113056483

主目錄

主目錄.....	I
圖目錄.....	II
一、 定義題目	1
二、 研究目標	1
三、 資料來源	1
四、 資料整理與觀察.....	2
五、 特徵值選取	4
六、 類神經網路的建模與驗證.....	5
七、 模型比較表	7
八、 結論	7
九、 程式碼連結	7

圖目錄

圖 1	資料集內容.....	1
圖 2	爬取出來的檔案內容.....	2
圖 3	缺失值比例.....	2
圖 4	出發量前十站分布圖.....	2
圖 5	每日轉乘租借次數.....	3
圖 6	星期別箱型圖.....	3
圖 7	月份箱型圖.....	3
圖 8	特徵值選取.....	4

一、 定義題目

預測任一天「全臺北市所有站點」因捷運／公車轉乘而產生的 YouBike 租借總量。

項目	說明
問題型別	單步時間序列迴歸 (Daily)
目標變數	daily_rent_count (整座城市每日轉乘租借量)
商業意義	提前一天掌握需求 → 車輛再平衡、假日加班排班、行銷預算配置・政策評估：大型活動 / 票價措施對轉乘量影響
成功判準	測試 MAE < 10 % 平均流量； $R^2 > 0.8$

二、 研究目標

- 預測任一天全市轉乘YouBike 租借總量，以利營運調度、假日人力與行銷預算配置。
- 建立兩條基準模型——Dense 神經網路與LightGBM——並比較效能。

三、 資料來源

資料集來自[台北市資料大平台](#)，其中挑選[臺北市轉乘 YouBike 租借資料](#)作為本專題的研究資料，包含 2023 整個年度的資料。

_id	借車時間	借車站	還車時間	還車站	租借時數	借車日期
1	2023-12-16T23:00:00+08:00	捷運公館站(2號出口)	2023-12-16T23:00:00+08:00	臺灣科技大學後門	00:04:56	2023-12-16
2	2023-12-16T23:00:00+08:00	文山行政中心	2023-12-16T23:00:00+08:00	和平東路三段291號	00:24:31	2023-12-16
3	2023-12-16T23:00:00+08:00	社子國小	2023-12-16T23:00:00+08:00	福安國中	00:09:44	2023-12-16
4	2023-12-16T23:00:00+08:00	和平東路二段18巷口	2023-12-16T23:00:00+08:00	捷運古亭站(2號出口)	00:10:27	2023-12-16
5	2023-12-16T23:00:00+08:00	民族玉門街口	2023-12-16T23:00:00+08:00	捷運西湖站(1號出口)	00:21:37	2023-12-16

四、資料整理與觀察

- 資料整理階段

- ◆ 爬取 12 個月份的資料，並統整為一個 CSV 檔。

	A	B	C	D	E	F	G	H
1	_id	_importdate	借車時間	借車站	還車時間	還車站	租借時數	借車日期
2	1	('date': '2025-03-26 14:02:17.859507', 'timezone_type': 3, 'timezone': 'Asia/Taipei')	2023-01-09T00:00:00+08:00	第二學士	2023-01-09T00:00:00+08:00	第二學士	00:04:39	2023/1/9
3	2	('date': '2025-03-26 14:02:17.870693', 'timezone_type': 3, 'timezone': 'Asia/Taipei')	2023-01-09T00:00:00+08:00	第二學士	2023-01-09T00:00:00+08:00	第二學士	00:02:56	2023/1/9
4	3	('date': '2025-03-26 14:02:17.872351', 'timezone_type': 3, 'timezone': 'Asia/Taipei')	2023-01-09T00:00:00+08:00	台北科技	2023-01-09T00:00:00+08:00	台北科技	00:06:10	2023/1/9
5	4	('date': '2025-03-26 14:02:17.873572', 'timezone_type': 3, 'timezone': 'Asia/Taipei')	2023-01-09T00:00:00+08:00	扶輪親恩	2023-01-09T00:00:00+08:00	扶輪親恩	00:09:50	2023/1/9
6	5	('date': '2025-03-26 14:02:17.874778', 'timezone_type': 3, 'timezone': 'Asia/Taipei')	2023-01-09T00:00:00+08:00	南京東路	2023-01-09T00:00:00+08:00	南京東路	00:11:26	2023/1/9
7	6	('date': '2025-03-26 14:02:17.876116', 'timezone_type': 3, 'timezone': 'Asia/Taipei')	2023-01-09T00:00:00+08:00	捷蓮士林	2023-01-09T00:00:00+08:00	捷蓮士林	00:15:48	2023/1/9
8	7	('date': '2025-03-26 14:02:17.877608', 'timezone_type': 3, 'timezone': 'Asia/Taipei')	2023-01-09T00:00:00+08:00	捷蓮西湖	2023-01-09T00:00:00+08:00	捷蓮西湖	00:07:24	2023/1/9
9	8	('date': '2025-03-26 14:02:17.878947', 'timezone_type': 3, 'timezone': 'Asia/Taipei')	2023-01-09T00:00:00+08:00	新生高第	2023-01-09T00:00:00+08:00	新生高第	00:11:37	2023/1/9
10	9	('date': '2025-03-26 14:02:17.880378', 'timezone_type': 3, 'timezone': 'Asia/Taipei')	2023-01-09T00:00:00+08:00	捷蓮水權	2023-01-09T00:00:00+08:00	捷蓮水權	00:07:17	2023/1/9
11	10	('date': '2025-03-26 14:02:17.881900', 'timezone_type': 3, 'timezone': 'Asia/Taipei')	2023-01-09T00:00:00+08:00	東海國中	2023-01-09T00:00:00+08:00	東海國中	00:03:33	2023/1/9
12	11	('date': '2025-03-26 14:02:17.883314', 'timezone_type': 3, 'timezone': 'Asia/Taipei')	2023-01-09T00:00:00+08:00	德行公園	2023-01-09T00:00:00+08:00	德行公園	00:24:36	2023/1/9
13	12	('date': '2025-03-26 14:02:17.884748', 'timezone_type': 3, 'timezone': 'Asia/Taipei')	2023-01-09T00:00:00+08:00	中山青島	2023-01-09T00:00:00+08:00	中山青島	00:06:08	2023/1/9

圖 2 爬取出來的檔案內容

- ◆ 補缺失值(每個欄位都沒有缺值，所以減少這步)

```

各欄位缺值比例：
_id          0.0
_importdate  0.0
start_time   0.0
start_station 0.0
end_time     0.0
end_station  0.0
duration_hour 0.0
rent_date    0.0
month        0.0
dtype: float64

```

圖 3 缺失值比例

- 視覺化觀察階段

- ◆ 出發量前十站，可以觀察到捷運公館站(2 號出口)的出發人數最多，2023 年約兩萬人。




圖 4 出發量前十站分布圖

- ◆ 每日總量折線圖，發現雨量較大（5 月梅雨、9 月颱風）出現局部低谷




圖 5 每日轉乘租借次數

- ◆ 星期別箱型圖，發現周末比較少人租借




圖 6 星期別箱型圖

- ◆ 月份箱型圖，九月波動最小




圖 7 月份箱型圖

五、特徵值選取

1. 最小可用日曆集

- ◆ `is_weekend` + `day_of_year` 兩個就能捕捉週期與年季節性，避免 One-Hot 過稀。

2. 關鍵滯後

- ◆ `lag_1/7/14` 各對應「昨天」「上週」「雙週」，既解釋又容易讓模型抓到自相關。

3. 多尺度趨勢

- ◆ `7 / 14 / 30` 天 rolling mean 讓模型知道「目前水平高低」與「短、中、長期波動」。

4. 風險/不確定度

- ◆ `rolling std` 提醒模型在高波動段降低過度擬合。

	A	B	C	D	E	F	G	H	I	J	K	L	M	N
1	rent_date	daily_rent	day_of_year	is_weekend	is_holiday	lag_1	lag_7	lag_14	roll_mean_7	roll_std_7	roll_mean_14	roll_std_14	roll_mean_30	roll_std_30
2	2023/1/1	770	1	1	0	770	770	770	1729.8571	818.71269	2158.4286	932.33221	1900.4333	1005.2383
3	2023/1/2	877	2	0	0	770	770	770	1729.8571	818.71269	2158.4286	932.33221	1900.4333	1005.2383
4	2023/1/3	2000	3	0	0	877	770	770	1729.8571	818.71269	2158.4286	932.33221	1900.4333	1005.2383
5	2023/1/4	2285	4	0	0	2000	770	770	1729.8571	818.71269	2158.4286	932.33221	1900.4333	1005.2383
6	2023/1/5	3000	5	0	0	2285	770	770	1729.8571	818.71269	2158.4286	932.33221	1900.4333	1005.2383
7	2023/1/6	1177	6	0	0	3000	770	770	1729.8571	818.71269	2158.4286	932.33221	1900.4333	1005.2383
8	2023/1/7	2000	7	1	0	1177	770	770	1729.8571	818.71269	2158.4286	932.33221	1900.4333	1005.2383
9	2023/1/8	2879	8	1	0	2000	770	770	2031.1429	794.30629	2158.4286	932.33221	1900.4333	1005.2383
10	2023/1/9	2964	9	0	0	2879	877	770	2329.2857	671.00515	2158.4286	932.33221	1900.4333	1005.2383

圖 8 特徵值選取

六、類神經網路的建模與驗證

將資料分成前 80%的時間(1-10 月份)與後 20%(11-12 月份)的時間，其中前 80%的資料會被輸入類神經網路建模，並利用後 20%的時間來驗證你模型的有效性。

此部分使用兩個不同的模型實作並做比較

◆ Dense Neural Network—架構細節

區段	參數	說明
輸入層	features = 16	13 個滯後 / 滾動特徵 + 2 日曆旗標 + 1 假日旗標
隱藏層 1	Dense 64 units, ReLU	高維投影，捕捉非線性 組合；He 初始化
	Dropout 0.2	隨機棄權 20 % 神經元， 抑制過擬合
隱藏層 2	Dense 32 units, ReLU	壓縮表示，提取關鍵特徵 模式
輸出層	Dense 1 unit (Linear)	輸出單一連續值 $\hat{y}$
優化器	Adam, lr = 0.001	自適應學習率收斂快
損失函數	MSE	與 RMSE 指標一致
批次大小	16	在 300 筆序列×16 批次 間取得平衡

設計理念：

- 用兩層 Fully-connected 足以對「每日總量」這種低維度特徵做近似；
- ReLU 配 He 初始化可避免梯度消失；
- Dropout 與早停共同防止小資料過擬合。

◆ LightGBM—架構細節

模組	參數	作用
基學習器	Gradient-based One-Side Sampling (GOSS) Leaf-Wise Growth	保留高梯度樣本以加速收斂；Leaf-Wise 可在同樣深度下取得更低損失。
關鍵超參	num_leaves = 63	葉節點數 $\approx$ 模型複雜度上限；理論上 $\text{num_leaves} \leq 2^{\{\text{max_depth}\}}$ 。
	feature_fraction = 0.8	每棵樹隨機取 80 % 特徵，降低相關度、減少過擬合。
	bagging_fraction = 0.8, bagging_freq = 5	每 5 棵樹隨機抽樣 80 % 資料，再搭配 GOSS 取梯度前段樣本。
正則化	正則化	L1 / L2 針對葉節點權重；對極長尾情況可加強。
學習率策略	learning_rate = 0.05 + 1 / 200 棵樹	小步長 + 多樹可提升泛化；早停自動裁剪過多樹。
Early-Stopping 回調	lgb.early_stopping(100)	驗證集 100 棵無改善即停止；防過擬合。
評估回調	lgb.log_evaluation(200)	每 200 棵列印一次 MAE；便於監控。

演算法流程（簡述）

1. 初始化：以目標均值作為第一棵樹的預測 F_0 。
2. 迭代 $t = 1 \cdots T$ ：
 - 計算殘差梯度 $g_i = \partial \text{Loss} / \partial F_{\{t-1\}}(x_i)$ 。
 - GOSS 保留 $|g|$ 最大的前 $a\%$ 樣本 + 隨機抽取 $b\%$ 的小梯度樣本 $\rightarrow$ 建樣本權重 w_i 。
 - 在權重樣本上做 Leaf-Wise 分裂，生成樹 h_t 。
 - 更新 $F_t(x) = F_{\{t-1\}}(x) + \eta \cdot h_t(x)$ 。
3. early-stopping：若驗證 MAE 100 棵無改善即停止，留最佳迭代 T^* 。
4. 最終輸出： $\hat{y} = F_{\{T^*\}}(x)$ 。

七、 模型比較表

指標	Dense NN	LightGBM
MAE (筆/日)	787.9	192.3
RMSE (筆/日)	1 085.4	307.2
1 - MAPE (%)	68 %	91 %
±10 % 容忍準確率	31 %	78 %
R^2	0.34	0.91

八、 結論

- 參數量並非越多越好：NN 雖參數少，但因序列樣本僅 365，仍易欠擬合；LightGBM 雖樹多，但 Leaf-Wise + 早停可自動修剪冗餘。
- LightGBM 模型在無外部天氣的情況下已能將 MAE 壓低至 ~192 筆/日，對平均 2 500 筆/日的流量僅約 8 % 誤差，足夠做營運決策參考。
- 如果加入天氣因素之後，效果可能可以更好

九、 程式碼連結

https://github.com/bc061789/Adanced_AI_Project/tree/main